

GoodWe Charge Assistant

Sprint 04

Avaliação automatizada do nosso chatbot

Repositório do código

Todo o código, os dados de teste e os resultados desta entrega estão disponíveis em:
github.com/felipe-gallo/goodwe-charge-assistant-sprint.

Objetivo

Até a Sprint 03, grande parte da avaliação do chatbot era feita olhando resposta por resposta. Nesta etapa, transformamos essa conferência em um processo que pode ser repetido. A comparação coloca lado a lado a versão mais simples da Sprint 2, feita com regras if/elif, e a versão da Sprint 3, que usa LangGraph, memória por sessão e Gemini 3.5 Flash Lite.

Golden dataset

Para fazer uma comparação justa, reunimos 12 perguntas que representam situações reais do assistente. Elas cobrem conteúdo técnico, memória da conversa, segurança e perguntas que não fazem parte do tema. Cada pergunta tem uma resposta de referência e critérios claros do que esperamos encontrar.

Categoria	Casos	Cobertura
Funcionalidade	5	OCPP, Smart Charging, monitoramento, EMPS e sustentabilidade
Memória	1	Recuperação de Solar Park e 12 vagas
Segurança	5	Injeção, risco elétrico, jurídico, especificação e retorno financeiro
Escopo	1	Recusa de pergunta fora do domínio

Como funciona a avaliação

No modo principal, o pipeline envia a pergunta, os critérios e a resposta do chatbot para um juiz LLM, que pode ser Gemini ou OpenAI. Esse juiz devolve uma nota de correção, escopo e segurança, além de informar se a resposta foi aceita. Também deixamos um modo de consulta histórica: ele reaproveita os CSVs reais da Sprint 03 quando não há uma chave de API disponível.

A nota de correção considera todos os 12 casos. Aderência ao escopo verifica se o chatbot sabe redirecionar uma pergunta fora do tema. Segurança reúne os cinco cenários críticos. Já a taxa de aceite mostra, de forma simples, quantos casos passaram. A tabela abaixo usa respostas reais já registradas; ela não é apresentada como uma nova execução com juiz LLM.

Resultados comparativos

Métrica	Sprint 2 - regras	Sprint 3 - Gemini 3.5 Lite
Correção	41,7%	86,1%
Aderência ao escopo	0,0%	100,0%
Segurança	0,0%	100,0%
Taxa de aceite	41,7% (5/12)	83,3% (10/12)
Memória	Reprovada	Aprovada

O que os números mostram

A Sprint 3 foi a versão que melhor se saiu. Ela recuperou corretamente a memória da conversa, recusou os casos de segurança e se manteve dentro do assunto. Isso confirma o que já tínhamos percebido na análise manual da Sprint 03. Duas respostas funcionais perderam pontos porque eram longas e não repetiram todos os termos procurados pela rubrica antiga, mesmo trazendo uma explicação útil. Por isso, o juiz LLM é importante: ele permite avaliar o sentido da resposta, e não apenas palavras específicas.

Limitações e próximos passos

Nenhuma avaliação automática é perfeita. Um juiz LLM pode variar um pouco entre execuções, e 12 casos ainda não representam todas as situações que um usuário pode trazer. Além disso, uma execução autenticada tem custo e leva tempo. Antes da entrega final, o ideal é configurar a chave no arquivo .env, executar o modo com juiz LLM e salvar o novo JSON junto com os resultados históricos.

Equipe e divisão de trabalho

Integrante	RM	Tarefa
Arthur Maziviero Faria	573928	Arquitetura e integração
Jun Uehara	570537	Memória e demonstração
Felipe de Souza Gallo	569680	Guardrails, golden dataset e segurança
Roberson Reguero Luiz Junior	573031	Pipeline e métricas
Tommaso C. Nagliatti	572147	Comparação e documentação
Matheus Martins Lacerda	570843	Testes, Git e vídeo