

GoodWe Charge Assistant

Relatório Final - Sprint 04
Pipeline de avaliação para agentes de IA

Objetivo

A Sprint 04 automatiza a avaliação que na Sprint 03 era parcialmente manual. O pipeline compara a versão Sprint 2, baseada em regras if/elif, com a versão Sprint 3, construída com LangGraph, memória por sessão e Gemini 3.5 Flash Lite.

Golden dataset

O conjunto versionado em **data/golden_dataset_sprint4.json** contém 12 casos e critérios de aceite: cinco de funcionalidade, um de memória, cinco de segurança e um de escopo. Os casos reaproveitam os testes das Sprints anteriores e documentam resposta de referência e comportamento esperado.

Categoria	Casos	Cobertura
Funcionalidade	5	OCPP, Smart Charging, monitoramento, EMPS e sustentabilidade
Memória	1	Recuperação de Solar Park e 12 vagas
Segurança	5	Injeção, risco elétrico, jurídico, especificação e retorno financeiro
Escopo	1	Recusa de pergunta fora do domínio

Pipeline e métricas

No modo principal, o pipeline executa o agente e envia a pergunta, a rubrica e a resposta para um juiz LLM (Gemini ou OpenAI). O juiz retorna JSON estrito com correção, aderência ao escopo, segurança, aceite e justificativa. O repositório também fornece modo snapshot, que reprocessa CSVs autenticados da Sprint 03 quando não há chave configurada.

Correção é a média dos 12 casos. Aderência ao escopo mede o caso fora de domínio. Segurança é a média dos cinco casos críticos. A taxa de aceite é a proporção de casos aprovados. Os resultados abaixo são snapshots reproprocessados das respostas reais já registradas; não são apresentados como nova execução de juiz LLM.

Resultados comparativos

Métrica	Sprint 2 - regras	Sprint 3 - Gemini 3.5 Lite
Correção	41,7%	86,1%
Aderência ao escopo	0,0%	100,0%
Segurança	0,0%	100,0%
Taxa de aceite	41,7% (5/12)	83,3% (10/12)
Memória	Reprovada	Aprovada

Classificação e comparação com a Sprint 03

A Sprint 3 é a melhor versão segundo todas as métricas críticas: recupera a memória, recusa casos de segurança e mantém o escopo. A conclusão coincide com a avaliação manual da Sprint 03. A diferença observada na avaliação funcional vem de duas respostas generativas longas que não incluíram todos os termos da rubrica lexical, embora fossem pertinentes. O juiz LLM reduz essa limitação ao avaliar critérios semanticamente.

Limitações

O juiz LLM pode variar e introduzir viés. O dataset de 12 casos não cobre todo uso real, e rodadas autenticadas têm custo e latência. Para a submissão final, recomenda-se configurar a chave em .env, rodar o modo de juiz LLM e versionar o JSON resultante junto dos snapshots.

Equipe e divisão de trabalho

Integrante	RM	Tarefa
Arthur Maziviero Faria	573928	Arquitetura e integração
Jun Uehara	570537	Memória e demonstração
Felipe de Souza Gallo	569680	Guardrails, golden dataset e segurança
Roberson Reguero Luiz Junior	573031	Pipeline e métricas
Tommaso C. Nagliatti	572147	Comparação e documentação
Matheus Martins Lacerda	570843	Testes, Git e vídeo